

语音转写 · 会议总结场景

离线转写长段不断句 测试报告与优化方案

Gemini 3.5 Transcribe 说话人分离与分段实测



测试报告 · 2026 年 9 月 · 两段真实音频 · 18 次对照运行



🎯 不是语速问题， 是分段机制与参数触发

四个发现、一条主方案，本页看完即可决策

18 次

对照运行

两段真实音频 · 英文 10 分钟 / 中文
24 分钟

1232 → 60

最长段字数

客户端二次切分后 · 中文崩塌版

4.6 vs 5.3

字/秒 · 长段 vs 短段

长段语速反而更慢 · 语速假设不成立


4.5 分钟

尾部漏转

开词级时间戳时 3 次运行止于 18:59

🔍 四个发现

- ① **分段单位 = 说话人轮次**: 轮次内部不按句切, 段长完全取决于说话人分离何时切换
- ② **语言提示触发大段**: 中文传 cmn-Hans-CN 稳定复现 272 秒单段, 34 轮对话并成 1 段
- ③ **与语速无关**: 长段语速 4.6 字/秒低于短段 5.3; 文字提示对分段完全无效
- ④ **尾部漏转**: 开词级时间戳时转写在 18:59 提前停止, 少 4.5 分钟约 1250 字




主方案: 词级时间戳客户端二次切分, 零成本、确定性


✅ 结论: 保持说话人分离与词级时间戳同开、中文不传语言提示、按 10 分钟分块、返回后本地二次切分——四步叠加, 最长段 1232 字 → 60 字且全文完整。

两段真实录音： 客服与访谈


16 kHz 单声道 WAV, 未做预处理




🇬🇧 英文 · 航空公司客服电话



- 时长 9 分 57 秒, 文件 19.1 MB
- 两人对话: 客服 Susan 与来电旅客, 改签回程航班
- 说话人轮次 34 个, 两人各 17 次, 交替规律
- 语速约 14.6 字符/秒, 长独白多, 最长轮次 65 秒
- 短应答少: 不超过 6 字符的轮次仅 3 个



🇨🇳 中文 · 人物访谈对谈




- 时长 23 分 37 秒, 文件 45.4 MB
- 主持人与嘉宾对谈, 围绕美与自我认同展开
- 说话人轮次 91 个, 两人各约 45 次, 穿插频繁
- 语速约 4.8 字/秒, 短应答密集: 15 个轮次不足 6 字
- 「对」「嗯」类一两字插话是分离难点所在



📌 读图要点: 色带是模型识别出的说话人轮次。中文访谈的色带切换比英文客服密得多, 短插话越多、越考验说话人分离——问题正是出在这段音频。

🧪 18 次对照运行： 一次只变一个变量

Google Cloud Vertex AI · Gen AI SDK 2.20




#	音频	变量	目的	关键结果
1	英文 10 min	默认: VERBATIM + 分离 + 词级时间戳	基线	34 段, 最长 890 字符 / 65 秒, 23 秒返回
2-3	中文 24 min	默认参数, 重跑一次	基线 + 确定性	两次逐字相同: 91 段, 最长 228 字
4-5	中文 24 min	language_codes=cmn-Hans-CN, 重跑	复现问题截图	两次逐字相同: 82 段, 最长 1232 字 / 272 秒
6	中文 24 min	language_codes=zh-CN	语言提示变体	68 段, 最长 2677 字 / 574 秒
7-8	中文 24 min	关闭词级时间戳(默认 / 加语言提示)	时间戳影响	82 / 85 段, 最长 745 / 642 字, 全文完整
9-10	中文 3 min 片段	音频旁附文字提示 / 不附	提示能否控制分段	两次逐字相同、token 相同: 提示被忽略
11-13	中文 5 min 分块	10-15 / 15-20 两块; 崩塌窗口 13:50-18:30 单独重跑	分块 / 长轮次重跑	22 + 26 段最长 242 字; 窗口 28 段最长 233 字
14-16	中文 10 min 分块	0-10 / 10-20 / 20-23:37 三块	完整覆盖验证	62 + 53 + 3 段, 合计 6690 字全文完整
17-18	中文 24 min / 尾段	max_output_tokens=65535; 18:50-23:37 尾段单独送	排除长度上限	与默认逐字相同仍止于 18:59; 尾段 4 段 1244 字完整

📖 读表要点: 所有运行默认同开说话人分离与词级时间戳; 2-3 与 4-5 两组各重跑一次结果逐字相同, 说明问题是参数触发的确定性行为。

🔧 五步测试流程

切片、调用、归档、统计、对照，全部脚本化



ffprobe / ffmpeg

run.py

results/*.json

analyze.py

run.py 变量矩阵

步骤	具体做法	产出物
① 探测切片	ffprobe 读采样率/声道/时长; ffmpeg 按秒切 3 / 5 / 10 分钟片段与问题窗口	clips/*.wav
② 调用模型	Gen AI SDK generate_content, 音频以字节内联; 参数由命令行开关控制	一次调用 = 一个 JSON
③ 归档返回	model_dump 全量落盘, 含每段 speaker_label、词级 start/end_offset 与 usage	results/*.json
④ 统计分析	按段计算字数、时长、语速、说话人分布; 定位最长段与内部停顿	段长/语速统计表

⑤ 对照重跑

同一文件只改一个变量重跑; 关键组各重跑两次核对确定性

18 次运行对照矩阵

统计口径

· 段 = 模型返回的一个 part

· 段时长 = 末词 end - 首词 start


· 语速 = 段字数 ÷ 段时长

· 长段 = 时长大于 30 秒

🔄 复现方式: 把音频路径换成自己的文件, 依次执行 run.py 与 analyze.py 即可得到同样的段长与语速统计。

一次调用： 四个配置项决定输出形态

24 分钟音频约 60 秒返回



run.py · 核心调用

```
1 from google import genai
2 from google.genai import types
3 client = genai.Client(vertexai=True, project=PROJECT_ID,
4                       location="global")
5 audio = types.Part.from_bytes(
6     data=open("meeting.wav", "rb").read(),
7     mime_type="audio/wav")
8 cfg = types.AudioTranscriptionConfig(
9     mode="VERBATIM",      # 逐字; SMART 与分离互斥
10    diarization=True,     # 说话人分离(保持开启)
11    word_timestamp=True,  # 词级时间戳
12    language_codes=None,  # 中文建议不传
13)
14 resp = client.models.generate_content(
15     model="gemini-3.5-transcribe-preview",
16     contents=[audio],
17     config=types.GenerateContentConfig(
18         audio_transcription_config=cfg))
19 parts = resp.candidates[0].content.parts # 每 part 一个轮次
```

四个配置项

mode: VERBATIM 逐字; SMART 会去口头禅但不能配分离与时间戳

diarization: 输出 speaker_label, 开启后单次音频上限 30 分钟

word_timestamp: 每个词的 start / end offset, 二次切分全靠它

language_codes: BCP-47 语言提示, 不传即自动检测



实测耗时: 10 分钟音频 23 秒, 24 分钟音频 60 秒

💡 音频直接以字节内联传入, 不需要先上传到存储桶; 24 分钟 WAV 一次请求约 3.9 万 token。

一个 part = 一个轮次, 内部不切

分段只在说话人切换处发生

 核心结论: 段落长度完全取决于说话人分离何时切换——切换没被识别, 段落就一直延长下去

英文音频 · 返回 JSON 节选

```
1  {"candidates": [{"content": {"parts": [
2    {"text": "Hello, Ryanair, Susan speaking. ...",
3     "audio_transcription": {
4       "speaker_label": "spk:0",
5       "words": [
6         {"word": "Hello,",
7          "start_offset": "14.100s", "end_offset": "14.700s"},
8         ...
9         {"word": "you?",
10          "start_offset": "17.200s", "end_offset": "17.500s"}]}]},
11   {"text": "Hello Susan. Thank you. ... (563 字符 / 44 秒)",
12    "audio_transcription": {"speaker_label": "spk:1",
13     "words": [ ... ]}}
14 ]}, {"finish_reason": "STOP"}]}
```

分段机制


- 每个 **part** = 一个连续的说话人轮次
- part 内只有 **text + words**, 没有句级边界
- 这次返回 **34 个 part**, Speaker 0 / 1 各 17 个
- 最长 part **563 字符 / 44 秒**: 一个人不换手地说 44 秒
- 官方**未提供**任何段长或句级分段参数




 推论: 要在小屏上按句显示, **不能指望模型**, 必须用 words 里的词级时间戳在**客户端重建分段**——这是后面主方案的出发点。

传语言提示 :13:53-18:25 合成一段

同一区间:默认 20 段, 加语言提示 1 段



Speaker 0 Speaker 1 每一块 = 一个段落



13:40-18:09

问题截图中的大段

客户环境返回 · 约 1200 字

13:53-18:25

我们复现的大段

1232 字 · 272 秒 · 与截图吻合

逐字相同


重跑两次的结果

参数触发的确定性问题, 非随机

⚠️ 触发条件明确: language_codes 传 cmn-Hans-CN 稳定复现; 传 zh-CN 更严重, 8:51-18:25 合成 2677 字单段。中文场景请先检查请求里是否带了语言提示。

独立裁判:加 语言提示不更准

2 人对谈 · 四种配置与裁判逐 轮对齐



裁判怎么做

- 用 **Gemini 3.8 Flash** 直接听音频判定: 全程 **2 人**, 211 轮
- 崩塌区间 13:53-18:25 实为 **34 轮交替**, 加提示版只识别 1 次切换
- 裁判轮次按文本对齐到各运行的 part, 统计切换数与标签一致率
- 识别文本与裁判相似度: 加 / 不加提示均为 **0.95**, 无差异


加提示: 文本不更准, 切换更少; 分块: 切换与标签双双改善。



结论: 中文不加 cmn-Hans-CN——四组对照中三组切换识别更差、文本无提升; 按 10 分钟分块收益最大: 切换 28 → 52 次、标签一致率 65% → 90%。

长段语速反而更慢, 停顿在、标签没切

长段 4.6 字/秒, 短段 5.3 字/秒



崩塌段内部到底 发生了什么

- 1232 字大段里有 **26 处 ≥ 1 秒** 的词间停顿, **48 处 ≥ 0.6 秒**
- 最长停顿 4.0 秒, 出现在「有。」与「看」之间
- 主持人的提问「那你觉得你有丧失过底气的时候吗」被并入嘉宾的段
- 停顿都被词级时间戳记录下来了, 缺的只是说话人标签切换



语速快 ≠ 大段
停顿在, 标签没切

结论: 大段不是「说得太快模型跟不上」, 而是说话人分离在特定参数下长时间不切换; 优化方向是分段与参数, 不是让用户放慢语速。

❌ 附加分段指令被忽略， 官方无段长参数

文字指令放前放后、中英文均被 丢弃




run.py --prompt · 文字提示实验

```
1 # 尝试:在音频 part 旁附加一段文字指令(前 / 后 / 中 / 英)
2 parts = [audio, types.Part.from_text(
3     text="请按句子分段输出,每段不超过40个字。")]
4 resp = client.models.generate_content(
5     model="gemini-3.5-transcribe-preview",
6     contents=parts, config=config)
7
8 # 结果(中文 3 分钟片段,说话人分离与词级时间戳开启):
9 # 不加文本: 19 段 / prompt_token 4850 / 最长 230 字
10 # 加文本 : 19 段 / prompt_token 4850 / 最长 230 字 <- 逐字相同
11 # 文本 token 未被计入 -> 文字指令在服务端被丢弃
```

提示词路线到此可以关闭:文字指令被静默 丢弃且不报错, 容易让排查走弯路。

📖 验证结果与文档口径


- 文本放音频前 / 后、中文 / 英文指令:输出逐字相同
- prompt token 与不加文本相同:文本在服务端被丢弃
- 模型卡明确:系统指令、多轮对话**不支持**, 不再展开
- 模型卡明确:**不暴露**段长参数, 建议客户端重建分段
- 结论:分段只能靠配置项与客户端后处理



📖 结论:转写模型只认配置对象、不认对话式指令;段长控制必须在客户端用词级时间戳完成, 提示词路线可以就此关闭。

! 24 分钟音频, 转写在 18:59 提前结束


结束原因 STOP, 输出仅 3400 token



证据链

- 默认参数两次运行与提高输出上限的运行, **三次都止于 18:59**, 少约 1250 字
- finish_reason 均为 **STOP**, 输出 3431 token 远未触顶
- 关闭词级时间戳、或传 zh-CN 提示时全文完整(约 6640 字)
- 18:50 起的尾段单独送入, 4 段 1244 字完整可转
- 按 10 分钟分块三段合计 6690 字, **覆盖完整**

对会议总结而言, 静默丢掉最后 4.5 分钟比断句问题影响更大, 建议一并处理。



防护建议: 调用后校验「末词 end_offset 与音频时长之差 < 30 秒」, 不满足即补跑尾段; 或直接按 10 分钟分块, 分块同时也缩短了最长段。

三条路径可叠加， 本地二次切分 为主

A 零成本确定, B、C 解决触发与覆盖



A · 客户端二次切分

- 用词级时间戳在停顿 / 句末标点 / 60 字上限处切分
- 纯本地、零额外调用、结果确定
- 崩塌版 82 段 → 223 段, 最长 1232 → 60 字
- 英文 34 段 → 160 段, 最长 890 → 128 字符

适用: 所有离线转写结果

代价: 无, 毫秒级本地计算



B · 请求参数调整

- 中文场景不传 language_codes
- diarization 与 word_timestamp 保持同开
- 不依赖 SMART 模式与文字提示
- 消除 272 / 574 秒单段的触发条件

适用: 中文及自动检测场景

代价: 需用自有音频回归识别率



C · 分块与长轮次重跑

- 长音频按 10 分钟分块, 分别转写后拼接
- 说话人标签一致率 **65% → 90%** (独立裁判对照)
- 修复尾部漏转, 最长段同步下降
- 跨块说话人标签需按重叠段对齐

适用: 超过 10 分钟的长音频

代价: 多次调用、需对齐跨块标签

推荐组合:

A + B 立即上线

C 随长音频一起启用

 落地顺序: 先改参数(B)、再接后处理(A), 长音频再加分块(C); 三步叠加后最长段 60 字、全文完整、说话人标签保留。

三条规则、三十行代码切出可读短句

只读 words 数组, 不改标签、不丢字

① 停顿切分(两档)

停顿 ≥ 1.5 秒无条件断开; 0.6–1.5 秒的停顿只在有标点或当前句 ≥ 20 字时断开, 避免把一句话切碎。



② 句末标点

上一词以 。 ! ? 等结尾且当前段 ≥ 8 字, 随句断开, 保证语义完整。



③ 字数上限

当前段 ≥ 60 字仍未断, 回退到最近的逗号处断开; 英文可放宽到 120 字符。



postprocess.py · split_turn 核心

```
1 END, CLAUSE = set("。 ! ? !?..."), set(", ,、 ; ;: :")
2 GAP, GAP_HARD, MAXC, MINC = 0.6, 1.5, 60, 8 # 短停顿 / 长停顿 / 上限 / 最短
3 def split_turn(turn): # turn = 一个说话人轮次, 标签原样保留
4     out, cur = [], []
5     def flush(): # cur 落成一个短句
6         if cur: out.append(seg(turn["spk"], cur)); cur.clear()
7     for w in turn["words"]:
8         if cur:
9             gap = start(w) - end(cur[-1])
10            n, last = len(join(cur)), cur[-1]["word"][-1]
11            punct = last in END or last in CLAUSE
12            long_pause = gap >= GAP_HARD # ① 长停顿:无条件切
13            short_pause = gap >= GAP and (punct or n >= 20) # ① 短停顿:有标点才切
14            if n >= MINC and (long_pause or short_pause or last in END):
15                flush() # ② 句末标点随句切
16            elif n >= MAXC: # ③ 字数上限兜底
17                k = last_index(cur, CLAUSE | END) # 回退到最近逗号
18                tail = cur[k+1:]; del cur[k+1:]; flush(); cur.extend(tail)
19            cur.append(w)
20    flush(); return out
```

 参数可调: 中文小屏建议 60 字 / 停顿 0.6 与 1.5 秒两档, 英文 120 字符; 阈值只影响段落粒度, 不影响识别文本与说话人标签。


方案 A · 效果对比(数字)

 处理前最长 272 秒,
处理后 13.5 秒

上排原始返回, 下排二次切分



■ Speaker 0 ■ Speaker 1 每一块 = 一个段落



82 → 223

中文 · 段落数

崩塌版返回 · 二次切分后

1232 → 60

中文 · 最长段字数

缩短 95%, 达到小屏可读粒度

272 → 13.5 秒

中文 · 最长段时长

字幕停留时间进入正常区间

890 → 128

英文 · 最长段字符

34 段 → 160 段, 上限 120 字符

✅ 二次切分对崩塌版与正常版同样有效: 默认参数版 91 段 → 217 段、最长 228 字也压到 60 字以内, 无论参数是否触发大段都值得做。

同一段话， 手机上的两种样子

左:原始返回;右:二次切分 · 带时间戳与 Speaker 标签



处理前 · 1 段 1232 字

处理后 · 每句独立成行

小屏上的差别


- 左侧:13:53-18:25 一段 **1232 字**, 需连续滚动约 **10 屏**, 中途没有任何时间锚点与说话人提示
- 右侧:同一段话切成 **短句**(最长 60 字), 每句前置 **时间戳 + Speaker 标签**
- 标签沿用模型原始输出, 二次切分**不改标签、不丢字**
- 每句可点击回放、可逐句引用进会议纪要

[13:53] Speaker 1 因为这事已经传了有20多年了。
[13:55] Speaker 1 我都无从去解释。
[14:00] Speaker 1 我有曾经跟别人讲, 我说如果这事OK如果是真的话, 20多年每天只吃几粒米的话.....

完整逐字对照见附录 A(中文 10 页)与附录 B(英文 4 页), 每句均带 Speaker 标签。

去掉触发条件， 补齐覆盖率

左图红色为需要规避的参数




B · 请求参数

- 中文不传 language_codes: 文本不更准，说话人切换反而更少
- 分离与词级时间戳同开: 关时间戳最长段反弹到 745 字
- 不用 SMART 模式与文字提示 (与分离互斥 / 无效)



C · 分块与长轮次重跑


- 10 分钟分块: 三段完整，最长 333 字，标签一致率 90%
- 崩塌窗口单独重跑: 28 段，最长 233 字
- 跨块标签需按边界重叠段对齐并抽检



📌 建议默认组合: 不传语言提示 + 10 分钟分块 + 二次切分。分块后单块 30 分钟上限与尾部漏转都不再是问题。

三条边界、 三步落地

两周内完成集成与回归验证



🚧 适用边界

- 本次验证范围为**离线文件转写**;说话人分离全程保持开启,二次切分不改动任何标签
- 开启说话人分离后**单次音频上限 30 分钟**,更长文件必须分块
- 访谈类短插话密集场景,说话人标签可能串位;二次切分不改标签,需抽检
- 词级时间戳开启会轻微降低识别准确率(官方口径),本测试未见明显影响



✅ 落地三步


- 第 1 步 · 改参数(1 天)**:检查现网请求是否传了 language_codes, 中文去掉;确认分离与词级时间戳同开
- 第 2 步 · 接后处理(2-3 天)**:集成 postprocess.py, 阈值 0.6 秒 / 60 字;加末词时间戳覆盖率校验
- 第 3 步 · 回归验证(1 周)**:用自有音频跑 analyze.py, 验收指标:最长段 ≤ 60 字、覆盖率 $\geq 98\%$



👉 交付物:脚本与本报告已发布在 github.com/codeat/gemini-transcribe-segmentation,可直接复跑核对每一个数字。

? 六个常见问题

全部建立在说话人分离开启的前提下



Q1 · 识别到说话人切换了，会不换行吗？

不会。每个 part 只有一个说话人标签，标签一变必然另起新段；全部运行 924 对相邻段中零例切换却连写。二次切分后每句独立成行并保留标签。

Q2 · 二次切分会改说话人标签或丢字吗？

不会。只读 words 数组逐字重组，附录 A / B 可逐字核对；输出每句都带 spk、start、end 三个字段，可直接渲染。

Q3 · 切分阈值怎么选？

中文小屏建议 60 字上限、停顿 0.6 / 1.5 秒两档，英文 120 字符；阈值只影响段落粒度，不影响识别文本与标签。

Q4 · 长音频怎么处理？

按 10 分钟分块送入，说话人分离与词级时间戳保持开启；调用后校验末词时间戳与音频时长之差 < 30 秒，即可保证覆盖完整。

Q5 · 为什么不用 SMART 模式自动分段？

SMART 与说话人分离、词级时间戳互斥；本方案在 VERBATIM 模式下同样得到干净的短句，且完整保留说话人标签。

Q6 · 上线前怎么验收？

用自有音频跑 analyze.py：最长段 ≤ 60 字、转写覆盖率 ≥ 98%、抽检说话人标签；三项达标即可上线，脚本随报告交付。

🔍 一句话：说话人一旦被识别为切换就一定分段；所有优化都建立在保留说话人标签之上，二次切分与分块都不改动标签。


第 1/10 段 · 13:53-14:23

128 字 → 5 句 · 最长一句 48 字

处理前 · 模型原始返回 13:53-18:25 Speaker 1 单段的第 1/10 部分

Speaker 1 因为这事已经传了有20多年了。我都无从去解释。我有曾经跟别人讲, 我说如果这事OK如果是真的话, 20多年每天只吃几粒米的话, 我觉得我天赋异禀。对, 就是太有意思了, 因为我很少跟别人不认识的人吃饭, 在偶尔的一些场合, 就是吃饭的时候真的会有人说哦卢昱你是吃东西的。

小屏视角: 整段 1232 字约需连续滚动 10 屏, 中途没有任何时间锚点





中文访谈 272 秒大段 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 60 字

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[13:53] Speaker 1 因为这事已经传了有20多年了。
[13:55] Speaker 1 我都无从去解释。
[14:00] Speaker 1 我有曾经跟别人讲, 我说如果这事OK如果是真的话, 20多年每天只吃几粒米的话, 我觉得我天赋异禀。
[14:12] Speaker 1 对, 就是太有意思了, 因为我很少跟别人不认识的人吃饭, 在偶尔的一些场合, 就是吃饭的时候真的会有人说
[14:21] Speaker 1 哦卢昱你是吃东西的。

第 2/10 段 ·
14:24–14:56

166 字 → 5 句 · 最长一句 52 字



处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 2/10 部分

Speaker 1: 我说不然呢？这样会有人经常就是很认真地看着我说那你对这种谣言或者关于你自己的这些什么心情呢？这些都触碰不到我，因为她太荒谬了，她跟我其实没有什么太大的关系。

小屏视角：整段 1232 字约需连续滚动 10 屏，中途没有任何时间锚点

但有一些会是影响到，你比如关于你的专业、关于你的节目，那个时候会影响到我，我就做更多的好的节目去直面她。我是专业的时候我就不信我盖不过你的声音，这点我太有自信了，所以我们得一直

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签


[14:24] Speaker 1 我说不然呢？这样会有人经常就是很认真地看着我说

[14:30] Speaker 1 那你对这种谣言或者关于你自己的这些什么心情呢？

[14:35] Speaker 1 这些都触碰不到我，因为她太荒谬了，她跟我其实没有什么太大的关系。

[14:41] Speaker 1 但有一些会是影响到，你比如关于你的专业、关于你的节目，那个时候会影响到我，我就做更多的好的节目去直面她。


[14:50] Speaker 1 我是专业的时候我就不信我盖不过你的声音，这点我太有自信了，所以我们得一直



中文访谈 272 秒大段 · 模型原始标签 Speaker 1，切分不改标签 · 阈值 0.6 秒 / 60 字

第 3/10 段 ·
14:56–15:23

125 字 → 5 句 · 最长一句 37 字




处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 3/10 部分

Speaker 1 一直在。然后有一天你就会特别强大地看这么三粒米，老娘吃的多少米根本不知道。那这一切就会盖过那所有的那些声音，没有比这更好的回击了。我认为我自己是一个手艺人。我的底气来自于我的手艺，我不知道你会怎么样去理解底气这两个字。我的底气来自于我对自己的信任吧。

小屏视角：整段 1232 字约需连续滚动 10 屏，中途没有任何时间锚点

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

- [14:56] Speaker 1** 一直在。然后有一天你就会特别强大地看这么三粒米，老娘吃的多少米根本不知道。
- [15:05] Speaker 1** 那这一切就会盖过那所有的那些声音，没有比这更好的回击了。
- [15:10] Speaker 1** 我认为我自己是一个手艺人。
- [15:12] Speaker 1** 我的底气来自于我的手艺，我不知道你会怎么样去理解底气这两个字。
- [15:19] Speaker 1** 我的底气来自于我对自己的信任吧。



中文访谈 272 秒大段 · 模型原始标签 Speaker 1，切分不改标签 · 阈值 0.6 秒 / 60 字

第 4/10 段 · 15:25–16:00

131 字 → 5 句 · 最长一句 51 字

处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 4/10 部分

Speaker 1: 就是我相信是OK我可以坐在这里我可以站在这里给大家表演可以坐在这里讲话大家可以听。那你觉得你有丧失过底气的时候吗？有。

小屏视角: 整段 1232 字约需连续滚动 10 屏, 中途没有任何时间锚点

看到一些评论的时候看到大家也都开始怀疑你的时候, 当一个人陷入这种痛苦的时候, 别人说什么她都听不见, 已经有无数人跟我讲过说其实挺好的呀我根本不信。

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签


[15:25] Speaker 1 就是我相信是OK我可以坐在这里我可以站在这里给大家表演

[15:33] Speaker 1 可以坐在这里讲话大家可以听。

[15:36] Speaker 1 那你觉得你有丧失过底气的时候吗？

[15:41] Speaker 1 有。看到一些评论的时候看到大家也都开始怀疑你的时候, 当一个人陷入这种痛苦的时候, 别人说什么她都听不见,

[15:54] Speaker 1 已经有无数人跟我讲过说其实挺好的呀我根本不信。



中文访谈 272 秒大段 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 60 字


 第 5/10 段 · 16:00–16:30

151 字 → 5 句 · 最长一句 54 字

处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 5/10 部分

Speaker 1 只有有一天你自己回过头去看，突然猛然想到说哎当年其实还是不错的，至少不值得我如此之痛苦的否定当时全部的一切。但只是此刻还没有到而已。对没有到。就跟如果你对自己不够自信，你觉得你自己不美的话，别人说哎经常你很美，你也感受不到自己的美是一样的。嗯。你觉得你自己最美的一点是什么？感受不吧。比如说对什么说不？

 小屏视角：整段 1232 字约需连续滚动 10 屏，中途没有任何时间锚点



中文访谈 272 秒大段 · 模型原始标签 Speaker 1，切分不改标签 · 阈值 0.6 秒 / 60 字

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[16:00] Speaker 1 只有有一天你自己回过头去看，突然猛然想到说哎当年其实还是不错的，至少不值得我如此之痛苦的否定当时全部的一切。
[16:12] Speaker 1 但只是此刻还没有到而已。
[16:15] Speaker 1 对没有到。就跟如果你对自己不够自信，你觉得你自己不美的话，别人说哎经常你很美，你也感受不到自己的美是一样的。
[16:23] Speaker 1 嗯。你觉得你自己最美的一点是什么？
[16:28] Speaker 1 感受不吧。比如说对什么说不？

第 6/10 段 · 16:30–16:58

140 字 → 5 句 · 最长一句 55 字

处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 6/10 部分

Speaker 1: 对工作说不。哇对机会说不。这点跟我想的真的不一样, 我一直以为你也是一个就是会对机会会很愿意抓住它, 然后有的时候会跟生活如果发生冲撞

小屏视角: 整段 1232 字约需连续滚动 10 屏, 中途没有任何时间锚点

的时候你就会觉得天哪, 此刻我该如何选择, 内心会很多的挣扎纠结。那你并没有, 你是怎么做到的, 一直能做自己。你能听到你心里所谓的那个声音一直在引领着你吗?

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签


[16:30] Speaker 1 对工作说不。哇对机会说不。

[16:35] Speaker 1 这点跟我想的真的不一样, 我一直以为你也是一个就是会对机会

[16:42] Speaker 1 会很愿意抓住它, 然后有的时候会跟生活如果发生冲撞的时候你就会觉得天哪, 此刻我该如何选择, 内心会很多的挣扎纠结。

[16:51] Speaker 1 那你并没有, 你是怎么做到的, 一直能做自己。

[16:55] Speaker 1 你能听到你心里所谓的那个声音一直在引领着你吗?



中文访谈 272 秒大段 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 60 字

第 7/10 段 · 16:58–17:23

96 字 → 5 句 · 最长一句 32 字




处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 7/10 部分

Speaker 1 就哪怕你那时候是拒绝的。我能感觉到其实有十个offer来我全拒掉，有一个是总也拒不掉的。就才是就是要推你走的那个东西。上海乐们这个就是拒不掉，后来上完百乐门之后就是米薇，她们要找我们去做喜剧。

小屏视角：整段 1232 字约需连续滚动 10 屏，中途没有任何时间锚点

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

- [16:58] Speaker 1 就哪怕你那时候是拒绝的。
- [17:01] Speaker 1 我能感觉到其实有十个offer来我全拒掉，有一个是总也拒不掉的。
- [17:12] Speaker 1 就才是就是要推你走的那个东西。
- [17:16] Speaker 1 上海乐们这个就是拒不掉，后来上完百乐门之后
- [17:20] Speaker 1 就是米薇，她们要找我们去做喜剧。



中文访谈 272 秒大段 · 模型原始标签 Speaker 1，切分不改标签 · 阈值 0.6 秒 / 60 字

 第 8/10 段 · 17:24–17:42

86 字 → 4 句 · 最长一句 33 字



处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 8/10 部分

Speaker 1: 飞来上海跟我们聊, 说来吧。去试试去北漂,
我们答应了。好妙。


 小屏视角: 整段 1232 字约需连续滚动 10 屏, 中途没有任何时间锚点

其实你一直有一点有你的拒绝, 但是你又允许命运引领着你往前走。带着拒绝往前走, 但还是走到你该要走的位置, 所以我老相信

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[17:24] Speaker 1 飞来上海跟我们聊, 说来吧。
[17:28] Speaker 1 去试试去北漂, 我们答应了。
[17:30] Speaker 1 好妙。其实你一直有一点有你的拒绝, 但是你又允许命运引领着你往前走。

[17:38] Speaker 1 带着拒绝往前走, 但还是走到你该要走的位置, 所以我老相信



中文访谈 272 秒大段 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 60 字

 第 9/10 段 · 17:43–18:08

128 字 → 4 句 · 最长一句 45 字




处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 9/10 部分

Speaker 1 人就是会又叫殊途同归, 又叫你带着你的剧本, 我带着我的剧本。我们的剧本终将把我们带到各自应该待的那个位置。我特别相信孟甜讲的一句话, 她的意思就是人最难的一件事情就是真正的属于自己或真正的终于自己。我觉得这是我想做的, 就是做一个完全终于自己和属于自己的一个人。

 小屏视角: 整段 1232 字约需连续滚动 10 屏, 中途没有任何时间锚点

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[17:43] Speaker 1 人就是会又叫殊途同归, 又叫你带着你的剧本, 我带着我的剧本。
[17:50] Speaker 1 我们的剧本终将把我们带到各自应该待的那个位置。
[17:54] Speaker 1 我特别相信孟甜讲的一句话, 她的意思就是人最难的一件事情就是真正的属于自己或真正的终于自己。
[18:02] Speaker 1 我觉得这是我想做的, 就是做一个完全终于自己和属于自己的一个人。



中文访谈 272 秒大段 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 60 字

 第 10/10 段 · 18:08–18:25



76 字 → 4 句 · 最长一句 33 字

处理前 · 模型原始返回 13:53–18:25 Speaker 1 单段的第 10/10 部分

Speaker 1: 终于自己真的是我今年找到的一个目标, 就是每分每秒都活出真实的自己。

 小屏视角: 整段 1232 字约需连续滚动 10 屏, 中途没有任何时间锚点

我觉得你还做得挺好的。就那么的能够笃定的选择挑选。对我来说我觉得我工作的时候是最美的。


处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[18:08] Speaker 1 终于自己真的是我今年找到的一个目标, 就是每分每秒都活出真实的自己。

[18:17] Speaker 1 我觉得你还做得挺好的。

[18:19] Speaker 1 就那么的能够笃定的选择挑选。


[18:23] Speaker 1 对我来说我觉得我工作的时候是最美的。



中文访谈 272 秒大段 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 60 字

 第 1/4 段 · 4:14-4:31

166 字符 → 4 句 · 最长一句 85 字符




处理前 · 模型原始返回 4:14-5:19 Speaker 1 单段的第 1/4 部分

Speaker 1 Right. Yeah. Yeah. Um now do you know what? I'm just I'm just wondering, Susan, because I've I've got you on the phone right now. So um it's only just occurred to me.

 小屏视角: 整段 880 字符约需连续滚动 7 屏, 中途没有任何时间锚点

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[4:14] Speaker 1 Right. Yeah.
[4:18] Speaker 1 Yeah. Um now do you know what?
[4:23] Speaker 1 I'm just I'm just wondering, Susan, because I've I've got you on the phone right now.
[4:28] Speaker 1 So um it's only just occurred to me.



英文客服 65 秒独白 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 120 字符

 第 2/4 段 · 4:32-4:46

247 字符 → 4 句 · 最长一句 72 字符

处理前 · 模型原始返回 4:14-5:19 Speaker 1 单段的第 2/4 部分

Speaker 1 : Obviously my work will be finished on Friday. I don't need to be in Brussels in Brussels anymore um for work purposes.


 小屏视角: 整段 880 字符约需连续滚动 7 屏, 中途没有任何时间锚点

Like I'm going for work on Wednesday and I'm working again on Friday, which is why I'm just going to stay instead of going home.

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[4:32] Speaker 1 Obviously my work will be finished on Friday.
[4:34] Speaker 1 I don't need to be in Brussels in Brussels anymore um for work purposes.
[4:39] Speaker 1 Like I'm going for work on Wednesday and I'm working again on Friday,

[4:43] Speaker 1 which is why I'm just going to stay instead of going home.



英文客服 65 秒独白 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 120 字符


第 3/4 段 ·
4:47-5:03

244 字符 → 4 句 · 最长一句 79 字符

处理前 · 模型原始返回 4:14-5:19 Speaker 1 单段的第 3/4 部分

Speaker 1 But I'm wondering. So if I was to book that 34 5 euro flight back that you told me about like for Friday night um but like later on today I might decide, you know what, while I'm there sure won't there be Christmas markets and everything. Won't

小屏视角: 整段 880 字符约需连续滚动 7 屏, 中途没有任何时间锚点



英文客服 65 秒独白 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 120 字符

处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[4:47] Speaker 1 But I'm wondering.
[4:48] Speaker 1 So if I was to book that 34 5 euro flight back that you told me about
[4:54] Speaker 1 like for Friday night um but like later on today I might decide, you know what,
[5:00] Speaker 1 while I'm there sure won't there be Christmas markets and everything.

 第 4/4 段 · 5:03–5:19

226 字符 → 4 句 · 最长一句 86 字符



处理前 · 模型原始返回 4:14–5:19 Speaker 1 单段的第 4/4 部分

Speaker 1: Won't it be lovely? And if I have a look around and I can actually get a hotel for pretty cheap um like do you


 小屏视角: 整段 880 字符约需连续滚动 7 屏, 中途没有任何时间锚点

think because it's next week do you think the flights are going to go up if I take a day or two to make up my mind?


处理后 · 客户端二次切分 同一区间 · 每句保留说话人标签

[5:03] Speaker 1 Won't it be lovely?
[5:05] Speaker 1 And if I have a look around and I can actually get a hotel for pretty cheap um

[5:11] Speaker 1 like do you think because it's next week
[5:14] Speaker 1 do you think the flights are going to go up if I take a day or two to make up my mind?



英文客服 65 秒独白 · 模型原始标签 Speaker 1, 切分不改标签 · 阈值 0.6 秒 / 120 字符



让每一句话都落在该在的位置。

感谢阅读。欢迎继续提供更多场景的测试音频，我们按同一套流程复跑并同步结果。
模型仍在公开预览阶段，正式上线前建议用自有音频再做一轮回归。

 随报告交付

github.com/codeat/gemini-transcribe-segmentation

- 调用 / 统计 / 后处理三个脚本 + 本报告 PDF
- 二次切分前后的完整文本